

Learning-Based Motion Control for Intelligent Vehicles:

A Taxonomy from a Closed-Loop Control Perspective

Qianyi Shen, Lin Zhang, Nan Li, *Member, IEEE*, Hong Chen, *Fellow, IEEE*, Jie Chen, *Fellow, IEEE*

Abstract—The growing integration of automated driving and chassis control requires vehicle motion controllers to handle nonlinear dynamics, uncertain tire-road conditions, actuator limits, and dynamic motion commands. Learning-based control can improve prediction, adaptation, command generation, and safety intervention when analytical models are inaccurate, fixed controllers are conservative, or online optimization exceeds real-time budgets. Even when two systems use the same learning method, their closed-loop implications depend on what the learned component changes and how its output enters the controller. This survey organizes learning-based vehicle motion control into three classes. Model Learning modifies the predictive representation. Policy Learning modifies command generation. Safety Constraint Learning represents or enforces admissibility and supports runtime safety intervention. Representative mechanisms and vehicle applications are compared using four common assessment dimensions: control performance, safety and robustness, real-time feasibility, and interpretability and verifiability. The synthesis shows that model, policy, and safety errors enter the closed loop through different paths and therefore require different validation evidence. Retaining a structured controller preserves explicit interfaces and constraints, but properties established for that controller do not automatically carry over to the combined system. Evaluation must cover the operating conditions under which the learned component remains valid, the complete runtime path, and intervention or fallback behavior when applicable.

Index Terms—Optimization and control, Data-based approaches, Autonomous driving, Learning-based control, Vehicle motion control

Closer integration allows chassis capability, uncertainty, and safety envelopes to inform planning and closed-loop control, while the chassis controller coordinates vehicle dynamics and multiple actuators under changing conditions [6], [7], [8].

Learning-based control (LBC) complements conventional model-based design when first-principles models are inaccurate, fixed controllers are overly conservative, or calibrated designs fail to generalize across operating conditions. Learned residual and predictive models can compensate for unmodeled dynamics in model predictive control (MPC) [9], adapt during repeated operation [10], update friction-related quantities [11], and improve autonomous racing control from collected data [12]. Learning can also refine a nominal policy near handling limits [13] or support safety-related constraint enforcement when an accurate model is unavailable [14]. These uses act on different parts of the closed loop: the predictive model, command generation, or safety and constraint handling.

Deploying these learned components involves more than nominal performance. Integrated planning and control must generate and track dynamically feasible motion [15], including high-performance maneuvers that require prediction and constraint handling across both functions [16]. Learned components can affect prediction, command execution, and safety intervention, so their resulting closed-loop behavior must be evaluated under distribution shift, hard constraints, and safety-critical interactions. Learned components often lack





TABLE V REPRESENTATIVE POLICY LEARNING PAPERS ORGANIZED BY THE CLOSED-LOOP ROLE OF THE LEARNED POLICY					
Role	Paper	Task	Policy function	Safety structure	Key trade-off
Hybrid policy learning	[13], [92]	autonomous racing	residual correction on nominal control	inherits nominal controller structure	+ low-cost upgrade on a working controller - limited authority may limit performance
	[95], [96]	active suspension	policy under external supervision	constrained by feasibility sets	+ stronger runtime safety interface - intervention may suppress policy benefit
	[99], [100]	lane changing	online arbitration and authority switching	verified switching and fallback	+ clear separation of performance and safety - switching logic becomes critical
Direct policy learning	[102]	urban driving	direct policy via differentiable training	training-structured support	+ direct differentiable optimization - weak explicit controller interface
	[104], [106]	E2E urban driving	joint trajectory-control prediction	internal trajectory guidance	+ more structure than pure action regression - still lacks explicit controller modularity
	[107], [108]	E2E urban driving	observation-to-action policy	representation and future-reasoning bias	+ fast and flexible policy inference - weaker interpretability and verifiability

关键创新：基于车辆运动控制系统闭环视角建立分类和评价体系

产业背景：智驾与底盘控制正在融合



❑ 智能底盘需求使车辆物理边界进入规划-控制链路

传统架构：上层规划，下层执行

- 通常采用“感知-规划-控制”的分层结构
- 上层规划根据环境信息生成参考轨迹、目标速度或运动意图
- 底盘控制通过转向、驱动、制动等执行器实现车辆运动


角色变化：下层判断可执行性，形成闭环反馈

- 智能底盘和一体化控制架构要求底盘控制需要承担更多闭环控制职责
- 底盘控制需要同时协调上层意图与**车辆动力学**、**执行器限制**和**稳定性边界**
- 上层运动意图能否执行，取决于当前车辆状态、道路条件和执行器能力

Integration Bottlenecks

Automated Driving Domain

- Motion intent to control command gap
- Reference feasibility under vehicle limits
- Prediction uncertainty in traffic interactions
- Time varying traffic and safety constraints



Chassis Domain


- Strongly coupled nonlinear vehicle dynamics
- Uncertain tire road adhesion conditions
- Actuator saturation and coordination limits
- Handling stability near physical limits

产业趋势：物理边界需要进入规划-控制链路，形成闭环

- 在高动态、安全关键或低附着工况下，车辆物理边界需要反馈到上层决策与规划中。

关键问题：上层运动控制意图如何在车辆物理约束下转化为底盘可安全执行的运动？

核心矛盾：规划可行 $\neq$ 底盘可执行



□ 上层认为可行的运动意图，在真实车辆物理约束下未必安全可执行

规划可行性主要来自环境与任务约束

- 上层规划通常关注道路边界、障碍物、交通规则和目标轨迹生成等
- 主要考虑几何可行性

底盘可执行性受车辆性能和物理边界约束


- 真实控制还受到轮胎附着、执行器饱和与响应滞后、载荷转移、横纵向耦合和操稳边界限制

极限工况下多类约束互相耦合

- 在高动态、低附着或紧急避障场景中，跟踪误差、稳定性、安全裕度和执行器能力不能独立处理


因此，底盘侧需要向上层反馈能力边界

- 运动控制不应只被动接收参考，还应把可行性裕度、模型不确定性和约束敏感性等信息反馈给规划-控制链路



两者融合的关键：运动控制不仅能执行参考，还要感知约束并反馈车辆能力边界

解决路径：学习型控制进入车辆运动控制闭环



□ 学习型算法的位置、功能与控制权

学习型算法模块解决上述问题的路径

改进预测模型

- 学习未建模动力学、路面附着和车辆参数变化，提升控制器对未来车辆响应的预测能力

生成或修正控制指令

- 学习难以解析设计的控制策略或残差补偿等，提升复杂工况下的控制适应性

约束安全可执行边界

- 学习安全包络、可行集等安全约束，将附着、稳定性和执行器限制等转化为可约束安全层

学习型算法可能引入的问题

名义性能≠安全可用

- 学习模块进入闭环后会影晌稳定性、轨迹可行性、碰撞避免
- 车辆运动控制系统受ISO 26262、ISO 21448/SOTIF制约

黑箱算法削弱分析接口


- 学习组件通常缺少清晰的稳定性、可行性和约束分析接口
- 同时影响闭环系统多个环节，黑箱算法故障及影响难以显式分析

接入位置决定验证要求

- 神经网络用于不同环节时对应不同控制权、失效模式和安全责任
- 对安全、合规提出更高要求

学习型控制的核心不是替代传统控制，而是以**明确闭环角色**和**可验证接口**增强车辆运动控制系统

现有基础与综述缺口：缺少闭环角色解释框架



□ 现有研究已展示潜力，但学习模块的闭环位置仍缺少统一解释

现有尝试：学习模块已进入闭环控制不同环节

改进预测模型

- 学习模型残差、车辆动力学、路面附着和参数变化，提升对未来车辆响应的预测能力

生成或修正控制指令

- 学习残差补偿、权重调节和控制策略等，提升非线性和极限工况下的控制性能

表达安全与可执行边界

- 学习安全包络、可行集等安全约束，将附着、稳定性和执行器限制等转化为可约束安全层

现有综述缺口：算法分类难以解释闭环含义

现有综述多围绕具体算法展开

- 现有综述多围绕 LBC 理论、learning-based MPC、DRL、IL 或自动驾驶应用任务展开

算法范式分类难以说明闭环功能


- 按算法范式分类，难以说明学习模块在闭环中的位置、修改什么控制功能、承担多少控制权

接入位置决定验证要求

- 不同接入位置对应不同接口、控制权、失效模式、安全责任和验证范围，对功能安全、可解释性和工程验证提出不同要求

关键缺口：如何把学习模块从**算法名称**分类转向**闭环控制角色**理解

本文视角：借鉴最优控制表达进行闭环角色分类



□ 分类依据：学习模块修改或替换了控制闭环中哪个组成部分

$$\min_{u_k} J(\cdot; \theta_J) \quad (1)$$

$$\text{s.t. } x_{k+1} = f(x_k, u_k; \theta_f) \quad (2)$$

$$g(\cdot; \theta_g) \leq 0 \quad (3)$$

$$u_k^* = \pi(x_k; \theta_\pi) \quad (4)$$

$f(\cdot)$: 车辆如何演化

- 学习模块用于改进预测模型、补偿模型误差或适应工况变化

$\pi(\cdot)$: 控制如何生成


- 学习模块用于修正传统控制器，或直接生成控制输出

$g(\cdot)$: 运动是否可执行

- 学习模块用于表达安全边界、可行域和运行时干预机制


$J(\cdot)$: 控制目标如何权衡

- 通常与前三类结合设计



学习算法只有放入闭环结构中，才能判断其作用对象、控制权限与失效后果

评价框架：从算法性能到闭环评价



❑ 学习模块进入闭环后，不能只用单一性能指标评价

评价框架

控制性能

复杂工况下的跟踪精度、
操稳质量与工况适应性

安全与鲁棒性

面对未知扰动、模型失配、
未见工况等，仍能约束风险并触发回退机制


实时部署性

计算复杂度、控制周期、
时延、硬件资源和数据代价满足车载要求

可解释性与可验证性

变量、接口和约束应足够清晰，便于分析、诊断、
验证和工程追溯

选文标准：聚焦车辆运动控制闭环



不按单一性能指标展开，而是在同一评价框架下分析不同学习模块的闭环角色和工程含义




TABLE I
OVERVIEW OF THE THREE MAIN FORMS OF LEARNING-BASED CONTROL IN INTELLIGENT VEHICLE MOTION CONTROL


Method	Summary
MODEL LEARNING	Learns the prediction model or model-related structure inside the control loop, so as to improve how the controller represents vehicle dynamics across fidelity, efficiency, and adaptation requirements. + Retains the model-based control architecture, with clearer mechanisms and more explicit physical meaning; + Can balance fidelity, efficiency, and adaptability through suitable model and integration design; - Often relies on costly data collection and sufficient coverage near handling limits and across conditions; - Offline modeling accuracy does not directly guarantee closed-loop reliability under feedback and prediction.
POLICY LEARNING	Learns the control policy on the controller side of the control loop, either as the main control law or as a learned component that complements a structured controller in the regimes hardest to handle analytically. + Offers high expressiveness with low online computational cost for fast and strongly nonlinear motion control tasks; + Supports flexible integration patterns, from direct control to residual correction and local refinement; - Usually provides weaker transparency and weaker assurance than model learning controllers with explicit structure; - Deployment is more sensitive to authority allocation, verification, and sim-to-real generalization.
SAFETY CONSTRAINT LEARNING	Learns safety boundaries, admissible sets, or supervisory mechanisms around the controller, so that safety knowledge can be represented, enforced, and monitored as an explicit layer in the control loop. + Captures safety knowledge that is hard to derive analytically under nonlinear handling limits and uncertainty; + Can work with both model-based and policy-based controllers as an explicit safety layer; - Stronger intervention often increases conservatism, runtime cost, or supervisory complexity; - Reliability still depends on unsafe-case coverage and robustness beyond the training domain.

关键问题

- 学习模块进入闭环的哪个位置
- 学习模块主要提升什么能力
- 学习模块带来什么验证和部署问题


正文重点：三类学习角色分别解决什么问题、带来什么代价

模型学习：改进控制器内部的预测表示



学习预测模型，缓解模型精度、实时性与适应性的三难平衡

路线	代表方法	控制作用	主要代价
提升模型精度	残差模型、神经动力学、PINN模型	补偿未建模非线性，提高极限工况预测质量	数据覆盖、黑箱程度、不确定性表达
提升实时性	Koopman / LPV / 凸化表示	将复杂非线性模型转化为更易在线优化的表示	表示误差、结构假设、适用区域限制
提升适应性	摩擦、轮胎、参数、控制权重或跨平台上下文	在路面、轮胎、载荷和平台变化下保持控制有效	在线估计可靠性、激励条件、有效域监测




统一判断

优势： 保留模型控制骨架，接口相对清晰，便于与MPC和约束处理结合


代价： 离线建模精度不等于闭环可靠性，仍需验证数据覆盖、有效域和在线计算成本

适用场景：控制器**闭环框架仍然可靠**，但内部模型需要更准、更快或更能适应工况变化

策略学习：改变控制命令生成



策略学习的关键：学习策略承担多少控制命令生成权限



学习策略越接近最终控制动作，闭环可靠性风险越高


统一判断

- 优势：表达能力强，可在强非线性、极限工况或复杂场景耦合下增强控制命令生成
- 代价：学习策略越接近最终动作，接口越不透明，越依赖数据覆盖、闭环验证、安全监督和回退设计

形式	学习模块作用	主要价值	主要代价
残差修正	在名义控制器基础上补偿未建模控制误差	保留控制骨架，低成本提升极限工况性能	改善幅度受残差权限限制
监督 / 切换	学习策略在安全监督、接管或回退机制下工作	在性能提升与安全兜底之间折中	监督器、切换逻辑和瞬态行为成为关键
直接策略	学习策略直接生成动作或控制相关轨迹	表达能力强，推理开销低，可处理复杂场景耦合	结构透明性弱，依赖数据覆盖、闭环验证和回退设计


适用场景：原有控制闭环架构难以覆盖复杂极限工况，需要考虑控制表达能力和闭环可靠性的权衡

安全约束学习：决定什么命令可以安全执行



❑ 不直接追求控制性能，而是让候选命令在执行前后受到安全边界约束

阶段	闭环作用	主要机制	主要代价
学习安全边界	把稳定性、附着和执行器限制转化为可查询边界	安全包络、可行域、障碍函数	表达能力与可证明性之间存在权衡
运行时安全过滤	在执行前修正或投影候选控制命令	控制动作投影、控制屏障函数、可微安全过滤器	可能带来保守性、抖振和实时计算负担
监测与回退	判断安全边界或控制器是否仍可信	运行时安全保证、分布外监测、回退控制	监督逻辑、触发条件和回退行为成为关键




统一判断

优势：可作为其它控制器的显式安全层，使复杂车辆安全约束能够进入闭环执行

代价：可靠性取决于边界有效域、训练/仿真覆盖和运行时监测机制；干预越强，越可能引入保守性与计算负担

适用场景：控制器安全性需要显式边界、过滤与回退保障

综合讨论：从学习角色到接入方式



从“学什么”到“控什么”

学习的作用对象决定控制功能的修改

学习角色	修改的控制功能	工程含义
模型学习	预测 / 适应	控制器依据什么预测未来
策略学习	命令生成	控制命令如何生成
安全约束学习	可执行性 / 监督	哪些命令可以被安全执行

接入方式决定闭环结构与命令权限


接入方式	控制器骨架	命令权限	主要含义
嵌入控制器内部	基本保留	修改内部模型、参数或约束	接口清楚，验证范围较局部
围绕控制器工作	部分保留	修正、过滤或切换候选命令	需要处理覆盖、切换和瞬态行为
作为主控制器	大部分替代	直接生成控制命令	表达能力强，但闭环验证和回退负担最大

学习模块越接近最终控制输出，表达能力越强，安全验证要求越高



同一种学习算法，嵌入不同控制功能和接入位置中，会对应完全不同的接口、失效模式和验证负担

工程挑战：学习模块需要闭环系统级验证



□ 性能收益能否实现，取决于学习模块与闭环系统的组合行为

1. 有效域需要界定

- 学习模型的误差与不确定性、学习策略的状态-动作覆盖、安全边界的适用范围，需要与速度、附着、轮胎饱和等**实际运行工况**相对应

2. 闭环交互需要评估

- 残差补偿策略、参数在线更新、安全约束都可能改变原控制器的输入输出关系；因此需要评估组合后的**稳定性、闭环行为和动态响应**

3. 实时执行必须可界定


- 车载闭环不仅要求平均推理速度，还要考虑最坏时延、抖动、在线优化和不确定性传播成本

4. 验证场景必须控制相关

- 验证应围绕速度范围、附着条件、轮胎饱和、执行器饱和、载荷变化、传感器退化和极限工况切换展开，而不是停留在通用算法性能指标上

学习模块的验证边界，应随其**闭环作用位置、控制权限和失效后果**一起定义

工程启示：从结构保留到高控制权学习



□ 近期更容易工程化的是角色边界清楚、控制权受限、验证范围局部的模块

近期落地：结构保留，学习增强

- 保留MPC、鲁棒控制或安全监督等结构化控制闭环骨架
- 学习模块主要修改模型、参数、约束或局部补偿项
- 接口边界较清楚，有效域和验证范围相对可定义
- 可叠加运行时监测与回退机制
- **潜在应用范围**：量产辅助驾驶、智能底盘控制、轨迹跟踪等

长期研究：提高学习模块控制权

- 直接策略或端到端策略可承担主要控制命令生成
- 表达能力强，在线推理快，适合复杂场景耦合
- 但数据覆盖、分布外工况和回退设计更难处理
- 控制责任边界和闭环验证证据要求更严格
- **潜在应用范围**：高动态实验平台、特定封闭场景、极限操纵或非量产验证系统


落地路径不是直接替代传统控制，而是从边界清晰、权限受限的学习模块**逐步扩展闭环作用范围**

结论：学习效果取决于闭环整体行为



学习型控制能否真正生效，需要在闭环控制系统视角下讨论

- 学习型车辆运动控制不应只按算法范式分类，而应在**控制系统闭环**中理解和分类
- 模型学习、策略学习和安全约束学习分别改变预测与适应、命令生成、可执行性约束与监督机制
- 学习模块的工程价值取决于其闭环作用对象、保留的控制器结构、承担的控制权限和有效域范围



学习型运动控制的核心不是替代传统控制，而是在**可解释、可验证、可监督的闭环**位置增强传统控制架构

Thank you !